



ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

**SUY LUẬN ĐỒ THỊ TRI THỨC THỜI GIAN
THEO CÂU TRUY VẤN THÔNG QUA TẠO
SINH TỪ TRI THỨC ĐA NGUỒN**

*(Query-Aware Temporal Knowledge Graph Reasoning with
Multi-Source Knowledge Based Generation)*

1 THÔNG TIN CHUNG

Người hướng dẫn:

– TS. Lê Ngọc Thành (Khoa Công nghệ Thông tin)

[Nhóm] Sinh viên thực hiện:

1. Nguyễn Khánh Nhân (MSSV: 21127657)
2. Đoàn Nam Thắng (MSSV: 21127740)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ 1/2025 đến 7/2025

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Trong thời đại công nghệ số, việc quản lý và khai thác tri thức từ dữ liệu ngày càng trở nên quan trọng. Đồ thị tri thức (Knowledge Graphs - KGs) [1] đã nổi lên như một công cụ mạnh mẽ để biểu diễn các mối quan hệ giữa các thực thể trong một cấu trúc có tổ chức. Đặc biệt, Đồ thị Tri thức Thời gian (Temporal Knowledge Graphs - TKGs) [2] mở rộng khả năng của KGs bằng cách thêm yếu tố thời gian vào các mối quan hệ, cho phép hệ thống nắm bắt sự thay đổi của tri thức theo thời gian.

Nêu vấn đề Một trong những thách thức lớn trong lĩnh vực này là bài toán *Temporal Knowledge Graph Reasoning* (TKGR) [3], tức là suy luận trên TKG để dự đoán các sự kiện tương lai dựa trên chuỗi sự kiện trong quá khứ. Tuy nhiên, các phương pháp hiện tại vẫn còn nhiều hạn chế:

- Chỉ tận dụng thông tin lịch sử bậc nhất mà chưa khai thác hiệu quả các mối quan hệ phức tạp hơn.
- Khả năng xử lý khối lượng thông tin lớn còn hạn chế, dẫn đến hiệu suất suy luận không cao.
- Thiếu tính giải thích trong quá trình suy luận, gây khó khăn cho việc hiểu và kiểm chứng kết quả.

Sự xuất hiện của các mô hình ngôn ngữ lớn (Large Language Models - LLMs) [4] như GPT [5], LLaMA [6] đã mở ra cơ hội mới cho TKGR nhờ khả năng xử lý ngữ nghĩa và suy luận vượt trội. Tuy nhiên, việc áp dụng LLMs vào TKGR vẫn gặp thách thức do:

- Các chiến lược prompt đơn giản chưa tận dụng hết tiềm năng của LLMs.
- Thiếu khả năng tùy chỉnh truy vấn cụ thể, dẫn đến kết quả suy luận thiếu

chính xác và không phù hợp với ngữ cảnh.

Ý tưởng giải quyết Để khắc phục những hạn chế này, nghiên cứu đề xuất phương pháp **MSKGen (Multi-Source Knowledge-Based Generation)**, một cách tiếp cận mới cho TKGR dựa trên tích hợp tri thức đa nguồn và tùy chỉnh truy vấn. MSKGen sử dụng LLMs để:

1. Trích xuất các quy tắc thời gian chất lượng cao từ dữ liệu lịch sử thông qua phương pháp học quy tắc logic.
2. Áp dụng kỹ thuật *Retrieval-Augmented Generation* (RAG) để tìm kiếm và tích hợp các tri thức liên quan từ nhiều nguồn khác nhau, đảm bảo tính phong phú và chính xác của dữ liệu đầu vào.
3. Kết hợp các tri thức này để tạo ra câu trả lời phù hợp với từng truy vấn cụ thể.

Phương pháp này không chỉ cải thiện độ chính xác mà còn tăng cường tính giải thích trong quá trình suy luận.

Phương pháp giải quyết Phương pháp MSKGen được xây dựng dựa trên ba thành phần chính:

1. **Trích xuất tri thức dựa trên quy tắc:** Sử dụng các bước đi ngẫu nhiên theo thời gian (temporal random walks) để trích xuất quy tắc logic từ dữ liệu lịch sử. Các quy tắc này được đánh giá chất lượng bằng thước đo Kulczynski và tinh chỉnh thông qua LLMs để đảm bảo độ chính xác cao nhất.
2. **Truy xuất tri thức ngữ nghĩa:** Áp dụng kỹ thuật RAG để tìm kiếm các sự kiện liên quan bằng cách sử dụng cơ sở dữ liệu vector (vector database). Điều này cho phép hệ thống tìm ra các sự kiện có nội dung tương tự về mặt ngữ nghĩa, ngay cả khi chúng không khớp hoàn toàn về cấu trúc hoặc biểu diễn.
3. **Lập luận đa nguồn:** Kết hợp các tri thức từ hai thành phần trên để tạo ra câu trả lời phù hợp với từng truy vấn thông qua một cơ chế hướng dẫn suy

luận (instruction-guided reasoning).

Hệ thống sau đó đánh giá và xếp hạng các câu trả lời dựa trên hai yếu tố: điểm số từ LLMs và điểm số từ mô hình đồ thị đã được huấn luyện trước.

Ý nghĩa thực tiễn của vấn đề Việc phát triển một phương pháp hiệu quả cho TKGR như MSKGen mang lại nhiều lợi ích thiết thực:

- **Dự đoán sự kiện tương lai:** Hỗ trợ ra quyết định trong các lĩnh vực như kinh tế, y tế, quản lý rủi ro bằng cách dự đoán xu hướng hoặc sự kiện sắp xảy ra dựa trên dữ liệu lịch sử.
- **Tăng cường khả năng hiểu biết ngữ cảnh:** Cải thiện hiệu suất của các hệ thống AI trong việc xử lý thông tin phức tạp và thay đổi theo thời gian, chẳng hạn như trợ lý ảo hoặc hệ thống khuyến nghị.
- **Ứng dụng trong giáo dục và nghiên cứu:** Hỗ trợ phân tích dữ liệu lịch sử trong nghiên cứu khoa học xã hội hoặc giáo dục bằng cách cung cấp những hiểu biết sâu sắc về sự tiến hóa của tri thức theo thời gian.

2.2 Mục tiêu đề tài

Lý do thực hiện Trong lĩnh vực suy luận trên Đồ thị Tri thức Thời gian (Temporal Knowledge Graph Reasoning - TKGR), các phương pháp hiện tại vẫn còn tồn tại nhiều hạn chế, gây khó khăn cho việc dự đoán chính xác các sự kiện tương lai dựa trên dữ liệu lịch sử. Các phương pháp truyền thống thường sử dụng cách tiếp cận truy xuất thông tin dựa trên lọc dữ liệu thông qua khớp lược đồ (schema matching). Điều này dẫn đến:

- **Khả năng khai thác tri thức lịch sử bị hạn chế:** Các phương pháp hiện tại chỉ tập trung vào việc lọc các sự kiện dựa trên cấu trúc biểu diễn mà không tận dụng được khả năng hiểu ngữ nghĩa sâu sắc của dữ liệu.
- **Thiếu suy luận theo truy vấn cụ thể:** Các mô hình hiện tại không tùy

chỉnh được quá trình suy luận theo từng truy vấn cụ thể, dẫn đến kết quả suy luận mang tính chung chung và không phù hợp với ngữ cảnh.

- **Hiệu suất thấp trong các nhiệm vụ phức tạp:** Việc thiếu sự tích hợp giữa các nguồn tri thức khác nhau làm giảm hiệu quả của các mô hình hiện tại trong việc xử lý các nhiệm vụ TKGR phức tạp.

Sự xuất hiện của các mô hình ngôn ngữ lớn (LLMs) như GPT, LLaMA đã mở ra cơ hội cải tiến đáng kể cho TKGR nhờ khả năng xử lý ngữ nghĩa vượt trội. Tuy nhiên, ứng dụng của LLMs trong TKGR vẫn chưa được khai thác hiệu quả do:

- Chưa tận dụng tối đa khả năng hiểu ngữ nghĩa của LLMs trong các nhiệm vụ TKGR.
- Các chiến lược truy xuất thông tin truyền thống không phù hợp với khả năng xử lý linh hoạt của LLMs.
- Thiếu cơ chế tích hợp tri thức đa nguồn để cải thiện độ chính xác và tính giải thích trong suy luận.

Do đó, việc nghiên cứu và phát triển một phương pháp mới như MSKGen là cần thiết để khắc phục những hạn chế này, đồng thời tận dụng tối đa tiềm năng của LLMs trong TKGR.

Ý nghĩa đề tài Đề tài nghiên cứu này mang lại ý nghĩa quan trọng trong việc giải quyết những khó khăn mà các phương pháp hiện tại đang gặp phải. Phương pháp MSKGen được đề xuất nhằm:

1. Tăng cường khả năng suy luận theo truy vấn cụ thể bằng cách tích hợp tri thức từ nhiều nguồn khác nhau và áp dụng kỹ thuật hướng dẫn suy luận (instruction-guided reasoning).
2. Cải thiện độ chính xác của quá trình dự đoán bằng cách sử dụng LLMs để trích xuất các quy tắc logic chất lượng cao từ dữ liệu lịch sử, đồng thời kết

hợp với kỹ thuật Retrieval-Augmented Generation (RAG) để tìm kiếm và tích hợp tri thức liên quan.

3. Nâng cao tính giải thích trong kết quả suy luận, giúp người dùng hiểu rõ hơn về quá trình ra quyết định của hệ thống.

Phương pháp này không chỉ giải quyết những hạn chế hiện tại mà còn mở ra tiềm năng ứng dụng rộng rãi trong nhiều lĩnh vực như kinh tế, y tế, giáo dục, và nghiên cứu khoa học.

Ảnh hưởng và ý nghĩa có thể có của kết quả Kết quả đạt được từ nghiên cứu này có ảnh hưởng sâu rộng đối với cả bài toán TKGR nói riêng và toàn bộ hướng nghiên cứu về Đồ thị Tri thức Thời gian nói chung. Cụ thể:

- **Vượt trội so với các phương pháp hiện tại:** Kết quả thực nghiệm cho thấy MSKGen vượt qua nhiều phương pháp tiên tiến (state-of-the-art) trong cùng lĩnh vực về độ chính xác và hiệu suất. Điều này chứng minh rằng việc tích hợp tri thức đa nguồn và tùy chỉnh truy vấn là cách tiếp cận hiệu quả hơn so với các phương pháp truyền thống.
- **Mở rộng tiềm năng ứng dụng:** Phương pháp MSKGen có thể được áp dụng vào nhiều lĩnh vực khác nhau như dự đoán xu hướng kinh tế, quản lý rủi ro y tế, hệ thống khuyến nghị, và trợ lý ảo thông minh. Điều này giúp tăng giá trị thực tiễn của nghiên cứu đối với đời sống xã hội.
- **Đóng góp vào hướng nghiên cứu lâu dài:** Nghiên cứu này không chỉ cung cấp một giải pháp cụ thể cho bài toán TKGR mà còn mở ra hướng nghiên cứu mới về tích hợp tri thức đa nguồn và sử dụng LLMs trong các nhiệm vụ suy luận phức tạp. Đây là nền tảng cho các nghiên cứu tiếp theo nhằm cải thiện hơn nữa khả năng xử lý dữ liệu thời gian.

2.3 Phạm vi của đề tài

Các đối tượng nghiên cứu Đề tài tập trung vào việc nghiên cứu các mô hình ngôn ngữ lớn (Large Language Models - LLMs) và Đồ thị Tri thức Thời gian (Temporal Knowledge Graphs - TKGs). Cụ thể:

- **LLMs:** Các mô hình như GPT, LLaMA được sử dụng làm nền tảng để thực hiện suy luận trên TKG. Các đặc điểm quan trọng của LLMs, bao gồm khả năng xử lý ngữ nghĩa và khả năng tùy chỉnh truy vấn, là yếu tố chính trong việc nâng cao hiệu suất suy luận.
- **TKGs:** Đồ thị tri thức với yếu tố thời gian được sử dụng để biểu diễn các sự kiện lịch sử và mối quan hệ giữa các thực thể. Đây là nguồn dữ liệu chính để thực hiện các nhiệm vụ dự đoán sự kiện tương lai.
- **RAG:** Retrieval-Augmented Generation (RAG) đóng vai trò quan trọng trong việc tích hợp dữ liệu từ nhiều nguồn khác nhau để cải thiện độ chính xác và tính giải thích của kết quả suy luận.

Thực thể liên quan Các thực thể liên quan trong đề tài bao gồm:

- **Mô hình sử dụng:** Các mô hình ngôn ngữ lớn như GPT và LLaMA được tích hợp vào framework MSKGen để thực hiện các nhiệm vụ suy luận. Ngoài ra, các mô hình khác như GPT-NeoX chỉ được sử dụng để so sánh hiệu suất với MSKGen.
- **Công cụ hỗ trợ:** Framework LangChain được sử dụng để xây dựng pipeline truy xuất tri thức và hướng dẫn suy luận. Điều này đảm bảo tính linh hoạt và khả năng mở rộng của hệ thống.

Tập dữ liệu Đề tài sử dụng các tập dữ liệu chuẩn trong lĩnh vực TKG reasoning để đánh giá hiệu quả của phương pháp MSKGen. Cụ thể:

- **ICEWS14:** Tập dữ liệu này chứa các sự kiện lịch sử với thông tin thời gian cụ thể, thường được sử dụng trong các nghiên cứu về TKG reasoning.

- **YAGO**: Một cơ sở dữ liệu lớn kết hợp WordNet (cơ sở dữ liệu về từ vựng) và thông tin từ Wikipedia. YAGO miêu tả đa dạng các thực thể trong thế giới thực và các mối quan hệ giữa chúng
- **GDEL**: Tập dữ liệu toàn cầu về sự kiện, cung cấp thông tin phong phú về các mối quan hệ giữa các thực thể qua nhiều thời điểm khác nhau.

Các tập dữ liệu này đều được chọn lọc kỹ lưỡng để đảm bảo tính đa dạng và độ phức tạp, từ đó đánh giá toàn diện hiệu suất của MSKGen.

Các giới hạn hoặc ràng buộc của đề tài Đề tài có một số giới hạn và ràng buộc nhất định:

- **Phạm vi nghiên cứu**: Đề tài chỉ tập trung vào bài toán suy luận trên Đồ thị Tri thức Thời gian (TKGR) và không mở rộng sang các bài toán khác như phân loại hoặc tìm kiếm thông tin trên đồ thị tri thức tĩnh (Static Knowledge Graphs).
- **Hạn chế về mô hình**: Chỉ sử dụng các mô hình ngôn ngữ lớn như GPT và LLaMA làm nền tảng cho phương pháp MSKGen. Các mô hình khác chỉ được dùng để so sánh hiệu suất chứ không phải là thành phần chính trong nghiên cứu.
- **Hạn chế về dữ liệu**: Chỉ sử dụng các tập dữ liệu chuẩn đã liệt kê ở trên để đảm bảo tính đồng nhất trong việc đánh giá. Việc áp dụng phương pháp này trên các tập dữ liệu mới hoặc chưa chuẩn hóa có thể yêu cầu thêm điều chỉnh.
- **Hạn chế về tài nguyên tính toán**: Do kích thước lớn của TKGs và chi phí tính toán cao khi tích hợp LLMs, phương pháp MSKGen được thiết kế để tối ưu hóa tài nguyên nhưng vẫn có giới hạn khi xử lý khối lượng dữ liệu cực lớn hoặc yêu cầu thời gian huấn luyện dài.

2.4 Cách tiếp cận dự kiến

Giới thiệu các nghiên cứu đã được tiến hành theo hướng nghiên cứu của đề tài Trong lĩnh vực suy luận trên Đồ thị Tri thức Thời gian (TKGR), việc tích hợp các Mô hình Ngôn ngữ Lớn (LLMs) đã được nghiên cứu rộng rãi nhằm nâng cao hiệu suất dự đoán sự kiện tương lai. Một số nghiên cứu nổi bật bao gồm:

- **GPT-NeoX-ICL** [7]: Nghiên cứu này tập trung vào việc áp dụng học trong ngữ cảnh (in-context learning) để thực hiện dự đoán với số lượng mẫu nhỏ. Phương pháp này sử dụng kỹ thuật prompt engineering để cải thiện độ chính xác của các dự đoán, cho thấy tiềm năng của LLMs trong việc xử lý các nhiệm vụ TKGR.
- **Chain-of-History (CoH)** [8]: CoH giới thiệu phương pháp suy luận từng bước để khai thác thông tin lịch sử bậc cao. Phương pháp này giải quyết hạn chế của việc xử lý khối lượng lớn thông tin lịch sử cùng một lúc, đồng thời cải thiện khả năng suy luận của LLMs bằng cách cung cấp chuỗi lịch sử bậc hai.
- **GenTKG** [9]: GenTKG phát triển một framework mới dựa trên Retrieval-Augmented Generation (RAG), kết hợp giữa truy xuất dựa trên quy tắc logic thời gian và tinh chỉnh tham số hiệu quả với số lượng mẫu nhỏ. Phương pháp này tối ưu hóa khả năng suy luận theo truy vấn cụ thể, vượt qua nhiều hạn chế của các phương pháp truyền thống.

Mặc dù các nghiên cứu trên đã đạt được những tiến bộ đáng kể, nhưng vẫn tồn tại một số thách thức chung:

- **Khả năng hiểu ngữ nghĩa chưa được tận dụng đầy đủ**: Các phương pháp hiện tại chỉ sử dụng cách truy xuất truyền thống, dựa vào khớp lược đồ mà không khai thác triệt để khả năng hiểu ngữ nghĩa của LLMs.
- **Thiếu suy luận theo truy vấn cụ thể**: Việc không tùy chỉnh quá trình suy luận theo từng truy vấn dẫn đến kết quả mang tính chung chung và thiếu

chính xác.

- **Hạn chế trong việc xử lý thông tin lịch sử phức tạp:** Các mô hình hiện tại gặp khó khăn khi xử lý khối lượng lớn dữ liệu lịch sử hoặc thông tin bậc cao.

Phương pháp và cách tiếp cận dự kiến Đề tài này đề xuất phương pháp MSKGen, một cách tiếp cận mới nhằm khắc phục những hạn chế hiện tại trong TKGR. Phương pháp này bao gồm các thành phần chính sau:

1. **Trích xuất quy tắc thời gian:** Sử dụng các bước đi ngẫu nhiên theo thời gian để trích xuất các quy tắc logic từ dữ liệu lịch sử. Các quy tắc này sẽ được tinh chỉnh thông qua LLMs nhằm đảm bảo độ chính xác cao nhất.
2. **Tích hợp tri thức đa nguồn:** Áp dụng kỹ thuật RAG để tìm kiếm và tích hợp tri thức liên quan từ nhiều nguồn khác nhau, đảm bảo tính phong phú và chính xác của dữ liệu đầu vào.
3. **Suy luận theo truy vấn cụ thể:** Kết hợp tri thức từ các nguồn khác nhau để tạo ra câu trả lời phù hợp với từng truy vấn thông qua cơ chế hướng dẫn suy luận (instruction-guided reasoning).

Sự khác biệt chính giữa MSKGen và các nghiên cứu trước đây nằm ở khả năng tích hợp tri thức đa nguồn và tùy chỉnh quá trình suy luận theo từng truy vấn cụ thể. Điều này không chỉ cải thiện độ chính xác mà còn tăng cường tính giải thích trong kết quả suy luận.

2.5 Kết quả dự kiến của đề tài

Kết quả của đề tài là một mô hình có thể giải quyết được bài toán dự đoán thực thể bị thiếu trong một bộ bốn của đồ thị tri thức theo thời gian.

Chúng tôi sẽ thực hiện đánh giá độ chính xác của mô hình chúng tôi với độ đo $Hit@N$ ($N=1, 3, 10$) trên 3 tập dữ liệu benchmark của đồ thị tri thức theo thời gian: ICEWS14 [10], GDELT [11] và YAGO [12].

Hiện tại, có tổng cộng 3 nhóm mô hình mà chúng tôi sẽ thực hiện so sánh với mô hình của chúng tôi:

- **Nhóm các mô hình sử dụng học sâu**
- **Nhóm các mô hình sử dụng rule**
- **Nhóm các mô hình sử dụng LLMs**

Kết quả kì vọng là mô hình của chúng tôi sẽ có thể đạt được độ chính xác cao hơn tất cả các mô hình khác ở cả ba độ đo trên ba tập dataset. Cụ thể, mô hình của chúng tôi sẽ có độ đo Hit@1 cao hơn từ 2-3% so với các mô hình khác ở cả ba tập dữ liệu. Còn với độ đo Hit@3 và Hit@10, chúng tôi mong đợi mô hình của chúng tôi vẫn sẽ đạt được độ chính xác cao hơn các mô hình khác từ 5-10%.

Sau khi đã thực hiện chạy kết quả và so sánh, nếu đạt được kết quả đúng như kì vọng thì đề tài này sẽ được viết thành một bài báo khoa học và nộp tại các hội nghị quốc tế vào tháng 3/2025 hoặc tháng 4/2025. Bài báo sẽ trình bày chi tiết về phương pháp nghiên cứu, kết quả đạt được và những đóng góp của đề tài đối với lĩnh vực đồ thị tri thức, qua đó khẳng định giá trị thực tiễn của nghiên cứu.

2.6 Kế hoạch thực hiện

Nội dung	Thời gian
Tìm hiểu về đề tài và các công trình nghiên cứu liên quan trước đây	01/01/2025 - 14/02/2025
Thu thập và tiền xử lí dữ liệu	15/02/2025 - 28/02/2025
Xây dựng, huấn luyện và đánh giá kết quả mô hình	01/03/2025 - 31/03/2025
Viết đề cương của đề tài	16/03/2025 - 31/03/2025
Viết bài báo khoa học về mô hình đã được xây dựng	01/04/2025 - 15/04/2025
Phát triển bài báo thành khóa luận tốt nghiệp	16/04/2025 - 07/2025

Bảng 1: Bảng kế hoạch thực hiện đề tài

Tài liệu

- [1] Hogan, A., Blomqvist, E., Cochez, M., et al.:Knowledge Graphs. *ACM Computing Surveys* 54(4), 1–37 (2021).
- [2] Ji, S., Pan, S., Cambria, E., et al.:A Survey on Knowledge Graphs: Representation, Acquisition, and Applications. *IEEE Transactions on Neural Networks and Learning Systems* 33(2), 494–514 (2022).
- [3] Peng, M., Liu, B., Xu, W., et al.:Deja vu: Contrastive Historical Modeling with Prefix-tuning for Temporal Knowledge Graph Reasoning. In: *Findings of the North American Chapter of the Association for Computational Linguistics (NAACL)*, pp. 1234–1245 (2024).
- [4] Brown, T., Mann, B., Ryder, N., et al.:Language Models are Few-Shot Learners. In: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, pp. 1877–1901 (2020).
- [5] Kalyan, K.S.:A Survey of GPT-3 Family Large Language Models Including ChatGPT and GPT-4 (2023).
- [6] Touvron, H., Lavril, T., Izacard, G., et al.:LLaMA: Open and Efficient Foundation Language Models (2023).
- [7] Black, S.M., Biderman, S., Hallahan, E., et al.:GPT-NeoX-20B: An Open-Source Autoregressive Language Model. In: *Proceedings of BigScience Episode 5*, pp. 95–136 (2022).
- [8] Liu, H., Wang, F., Chen, X., et al.:Chain-of-History: A Novel Approach to Temporal Reasoning. In: *ACL*, (2024).
- [9] Liao, R., Jia, X., Ma, Y., et al.:GenTKG: Generative Forecasting on Temporal Knowledge Graph with Large Language Models(2024).
- [10] Boschee, E., Lautenschlager, J., O’Brien, S., Shellman, S.:ICEWS14 Dataset

- [11] Schrodtt, P.A., Leetaru, K.:GDELT—Global Data on Events, Location, and Tone (2013).
- [12] Mahdisoltani, F., Biega, J., Suchanek, F.: YAGO3:A Knowledge Base from Multilingual Wikipedias.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 22 tháng 7 năm 2025
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)